

HealthSearch - Motor de Busca Híbrido com BM25 e Busca Semântica Vetorial

Relatório técnico - Desafio Integrador | UNIPÊ - Tendências em Ciência da Computação

1. Objetivo e arquitetura da solução

O HealthSearch foi construído para combinar a precisão lexical do Okapi BM25 com a capacidade contextual dos embeddings. O corpus contém as seis diretrizes médicas definidas no enunciado. A consulta passa por pré-processamento, é executada em paralelo nos motores léxico e semântico e, ao final, os rankings são fundidos por Reciprocal Rank Fusion (RRF). A interface em Streamlit permite comparar os resultados e calibrar os parâmetros do BM25.

1. Pré-processamento minúsculas, limpeza, tokenização e stopwords	2. BM25 ranking lexical k1 e b interativos	3. Embeddings vetores densos + similaridade de cosseno	4. RRF fusão dos ranks α e k=60	5. Streamlit abas, métricas e matriz comparativa
---	---	--	---	--


2. Implementação técnica

Componente	Implementação
Pré-processamento	Normalização para minúsculas, remoção de caracteres especiais, tokenização e eliminação de stopwords em português. O título e o trecho clínico são combinados como texto pesquisável.
BM25	Biblioteca <i>rank_bm25</i> com k1 ajustável de 0,0 a 3,0 (padrão 1,2) e b de 0,0 a 1,0 (padrão 0,75).
Busca semântica	Modelo <i>sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2</i> . Os vetores são normalizados e a similaridade de cosseno é calculada por produto escalar.
RRF	$Score_RRF(D) = \alpha/[60 + Rank_BM25] + (1-\alpha)/[60 + Rank_Semântico]$. O α é interativo e a constante k_RRF permanece fixa em 60.
Interface e bônus	Abas para BM25, Semântico, RRF, Matriz Comparativa e Cross-Encoder. O bônus aplica <i>cross-encoder/ms-marco-MiniLM-L-6-v2</i> aos Top-3 do RRF e mostra a variação de posição.

Decisão de projeto: foi utilizado um modelo multilíngue de embeddings para favorecer consultas em português. O Cross-Encoder do bônus é carregado apenas quando o usuário ativa o checkbox, reduzindo custo de execução no fluxo normal.

3. Comparação de ranks e estratégia de validação

A validação foi organizada em dois tipos de consulta: (a) **código exato**, em que o BM25 tende a ser mais preciso; e (b) **sinônimo clínico**, em que a busca semântica tende a recuperar o documento relevante mesmo sem coincidência literal. O gráfico abaixo representa o comportamento esperado do protótipo: o RRF mantém o documento relevante nas primeiras posições ao combinar as duas fontes de ranking.



Leitura do gráfico: no caso de código exato (**CÓD-ECG-12D**), o Doc 1 ocupa a 1ª posição no BM25 e o RRF preserva essa evidência. No caso de sinônimo clínico (**ataque cardíaco**), o Doc 2 melhora de 2º no BM25 para 1º no ranking semântico; o RRF mantém o documento relevante em 1º. Os dois casos representam os comportamentos centrais avaliados no projeto.

4. Critérios atendidos

Critério	Evidência na aplicação
BM25 e parâmetros	Sliders de k1 e b recriam o BM25 a cada interação e atualizam o ranking.
Semântico	Embeddings densos + similaridade de cosseno para contexto e sinônimos.
RRF	Fórmula ponderada implementada com ranks 1-based e k=60.
Interface	Dashboard Streamlit com abas, métricas, tabela de comparação e visualização dos ranks.
Bônus	Checkbox de Cross-Encoder nos Top-3 do RRF, exibindo ranking antes/depois.

5. Desenvolvimento individual

O trabalho foi realizado individualmente.

Responsável	Atividade
Autor do trabalho	Responsável por todas as etapas: pré-processamento do corpus, BM25 e calibração, busca semântica, RRF, interface Streamlit, testes, Cross-Encoder e relatório técnico.

Conclusão: a solução demonstra a complementaridade entre busca lexical e semântica. O BM25 preserva precisão em códigos e termos exatos, enquanto embeddings ampliam a cobertura para consultas conceitualmente equivalentes; o RRF integra ambas sem normalizar diretamente os scores.